

# Approximately Optimal Approximate Reinforcement Learning

**Kakade** SHAM@GATSBY.UCL.AC.UK  
Computational Neuroscience Unit, UCL, London WC1N 3AR, UK  
**Langford** JCL@CMU.EDU  
Computer Science Department, Carnegie-Mellon University, 5000 Forbes Avenue, Pittsburgh, PA 15213

## 【强化学习 91】Kakade&Langford 02'



张楚琦  
清华大学 交叉信息院博士在读

20 人赞同了该文章

这么有名的一篇工作竟然没有笔记，今天重新看了一下，补一下笔记。

### 原文传送门

[Kakade, Sham, and John Langford. "Approximately optimal approximate reinforcement learning." ICML. Vol. 2. 2002.](#)

### 特色

提出了 conservative policy iteration (CPI)，在理论分析上使用 restart distribution 来处理探索难的问题，并且把策略评估步 (policy evaluation) 和策略改进步 (policy improvement) 打包形成一个 greedy policy chooser。规定这个 greedy policy chooser 的误差为  $\epsilon$ ，代表这两步综合的 approximation error。文章证明了，当给定  $\epsilon$  时，CPI 方法：1) 能在某种 metric 下保证 policy improvement；2) 能在有限次调用 greedy policy chooser 之后结束；3) 最终的策略 near-optimal。

### 过程

#### 1. 主要想法

这篇文章提出 restart distribution 和 greedy policy chooser。具体细节后面都会再提到。

- Restart distribution: 策略梯度方法把 exploration 和 exploitation 交杂在一起，即使用当前的 (随机) 策略进行 rollout 产生样本，然后计算在样本上的策略梯度，并用于更新当前样本。因此对于状态空间的探索全靠当前策略产生，如果当前策略使得某一些重要的状态很难被探索到，则很难学习到最优策略。Restart distribution 的主要想法是，既然全凭当前策略无法充分覆盖状态空间，那么可以让 rollout 的初始状态分布尽可能覆盖到整个状态空间，这样就从另一个角度解决了探索的难题 (至少在理论分析上)。

- Greedy policy chooser: 如果策略估计步估计准确 (exact case), 那么每次就选择相对于所估计的价值函数的 greedy policy 即可 (one step improvement), 这样的操作可以保证 policy improvement 和 optimality, 这其实就是 dynamic programming。但是如果策略估计步不准确, 那么每次还选择相对于这个不准确估计的 greedy policy, 就不能再保证 policy improvement 了。如果策略估计步使用函数近似 (approximate case), 那么就不能保证最后选择出来的 greedy policy 对应最大的 one step improvement。文章假设在每一步上, 该 greedy policy chooser 选择到的策略距离最大的 one step improvement 相差小于  $\epsilon$ 。
- 考虑以上两个部分之后, 文章设计了 CPI 使得: 1) 能在某种 metric 下保证 policy improvement; 2) 能在有限次调用 greedy policy chooser 之后结束; 3) 最终的策略 near-optimal。

## 2. 之前的方法

文章说, 希望能够设计一个算法使得理论上能够对于以下三个问题有保障:

- (1) Is there some performance measure that is guaranteed to improve at every step?
- (2) How difficult is it to verify if a particular update improves this measure?
- (3) After a reasonable number of policy updates, what performance level is obtained?

知乎 @张楚珩

第一个问题是讲, 能不能保障 policy improvement, 该 policy improvement 可以不是最后关心的那个 policy performance, 而是自己定义的某种 policy performance measure。第二个问题是讲, 如果能够保障 policy improvement, 那么有没有什么判定依据使得我们知道这一轮还能不能产生相应的 policy improvement。它是在第一个问题基础上提出的, 即只有第一个问题有肯定的回答, 才会有第二个问题。第三个问题是说, 能不能在有限次更新之后得到一个 optimality 的保障, 即希望有一个 finite iteration analysis 而不是一个笼统的 convergence and asymptotic analysis。

### 2.1 Exact value function methods (e.g. policy iteration)

对于一个策略  $\pi$ , 每次计算得到  $Q_{\pi}(s, a)$ , 然后把策略更新为相对于  $Q_{\pi}(s, a)$  的 greedy policy

$$\pi'(a; s) \text{ such that } \pi'(a; s) = 1 \text{ iff } a \in \operatorname{argmax}_a Q_{\pi}(s, a).$$

(Puterman, 1994) 书中说明这种方法能够保证收敛到 optimal。

### 2.2 Approximate value function methods

不再能够得到一个准确的价值函数估计, 而是得到一个近似估计  $\tilde{V}(s)$ , 满足

$$\epsilon = \max_s |\tilde{V}(s) - V_{\pi}(s)|$$

$\pi'$  是  $\tilde{V}(s)$  对应的 greedy policy (这里不太明白,  $V$  函数如何对应相应的 greedy policy, 大概认为这里是用的类似 Sutton 书 Chap 6.8 里面讲的 afterstate value function 吧)。这种情况下, 不能保证 policy improvement, 只能保证性能减小的不太多, 即

$$(3.1) \quad V_{\pi'}(s) \geq V_{\pi}(s) - \frac{2\gamma\epsilon}{1-\gamma}.$$

从上式可以看出，exact case 时  $\epsilon=0$ ，能保证 policy improvement。太

这说明，该方法不能回答前述第 1、2 个问题。

### 2.3 Policy gradient methods

文章中说明要准确估计 policy gradient 的方向所需要的样本会非常多。

文章举了一个 sparse reward 的例子，即，除了一个目标状态之外，其他状态上的奖励都为零。

- On-policy: 在该例子中，在策略 far from optimal 的时候，如果让策略去随机采样产生 rollout，需要指数级多的样本才能够采样到目标状态。如果采样不到目标状态，那么估计的策略梯度为零，这样策略也不会做任何更新。
- Off-policy: 另外一种自然的想法就是使用更容易到达目标状态的 off-policy 的轨迹来计算策略梯度，同时为了弥补相应的分布的不同，再乘上 importance weight，这其中对应的 importance weight 就会指数级地小，这样在有用的策略梯度方向上只会产生一个很小的值。（文章中说这种情况下 importance weight 会指数级地大，我觉得是弄反了）

有文章提到策略梯度能够较为准确地被估计，不过注意到在文章中的例子上，策略梯度为零其实是一个比较准确的估计，但是它可能使得收敛指数级地慢。

## 3. Conservative policy iteration

### 3.1 Conservative policy update and policy improvement lower bound

这篇文章最重要的观察是：对于一个任意的策略  $\pi'$ ，只要它能产生一个正的 one step improvement，那么就能够找到一个相应的 conservative update  $\pi_{\text{new}}$ ，使得新策略相比于旧策略有 policy improvement。具体的细节如下。

Policy improvement 可以写作（performance difference lemma）：

**Lemma 6.1.** *For any policies  $\tilde{\pi}$  and  $\pi$  and any starting state distribution  $\mu$ ,*

$$\eta_{\mu}(\tilde{\pi}) - \eta_{\mu}(\pi) = \frac{1}{1-\gamma} E_{(a,s) \sim \tilde{\pi} d_{\tilde{\pi},\mu}} [A_{\pi}(s,a)]$$

而 one step improvement（policy advantage）可以写作：

$$\mathbb{A}_{\pi,\mu}(\pi') \equiv E_{s \sim d_{\pi,\mu}} [E_{a \sim \pi'(a;s)} [A_{\pi}(s,a)]] .$$

注意到两者的区别在于 state-action 的分布。在文中，最后关心的性能是在初始状态分布  $d$  下得到的性能，即  $\eta_d(\pi)$ ；这里考虑的是一个在状态空间中分布更为均匀的 restart distribution  $\mu$  下得到的性能，即  $\eta_{\mu}(\pi)$ 。

考虑一个 conservative update rule

$$(4.1) \quad \pi_{\text{new}}(a;s) = (1-\alpha)\pi(a;s) + \alpha\pi'(a;s),$$

利用 policy gradient theorem（Sutton 书）可以得到

$$\frac{\partial \eta_{\mu}}{\partial \alpha} \Big|_{\alpha=0} = \frac{1}{1-\gamma} \mathbb{A}_{\pi,\mu}$$

$$(4.2) \quad \Delta\eta_\mu = \frac{\alpha}{1-\gamma} \mathbb{A}_{\pi,\mu}(\pi') + O(\alpha^2).$$

这个性质告诉我们，只要这个任意的策略  $\pi'$  使得 one step improvement 大于零，那么我们至少能够用  $0 < \alpha \ll 1$  构造一个 conservative policy 使得该策略有大于零的 policy improvement。

那么选择一个怎样的  $\alpha$  能够获取一个最大的 policy improvement lower bound 呢？顺着这个思路往下，考虑给定  $\alpha$ ，计算 policy improvement 的下界。

**Theorem 4.1.** Let  $\mathbb{A}$  be the policy advantage of  $\pi'$  with respect to  $\pi$  and  $\mu$ . and let  $\epsilon = \max_s |E_{a \sim \pi'(a;s)} [A_\pi(s,a)]|$ . For the update rule 4.1 and for all  $\alpha \in [0, 1]$ :

$$\eta_\mu(\pi_{\text{new}}) - \eta_\mu(\pi) \geq \frac{\alpha}{1-\gamma} \left( \mathbb{A} - \frac{2\alpha\gamma\epsilon}{1-\gamma(1-\alpha)} \right).$$

知乎 @张楚珩

由于这个定理比较重要，因此加了一个红框框。定理的推导也比较直观，policy improvement 和 one step policy improvement 差距产生的原因就在于策略不同导致相应的状态分布不一样。而根据 conservative policy update rule，这两个比较的策略每一步至少有  $1-\alpha$  的概率选择相同的行动，从而产生相同的状态分布；而不同的那一部分遵循  $\pi'$ ，而我们已知它所带来的 one step improvement；剔除这两部分之后，bound 剩余的项即可得到上述定理。

比较有意思的是当  $\alpha \rightarrow 0$  时，上述定理变为

$$\eta_\mu(\pi_{\text{new}}) - \eta_\mu(\pi) \geq \frac{\mathbb{A}}{1-\gamma} - \frac{2\gamma\epsilon}{1-\gamma}$$

其形式上和 (3.1) 类似，不过两处地方  $\epsilon$  的含义不太一样，这里是

$\epsilon = \max_s |E_{a \sim \pi'} [A_\pi(s,a)]| = \max_s |Q_\pi(s,a) - V_\pi(s)|$ ，而 (3.1) 中为  $\epsilon = \max_s |\tilde{V}(s) - V_\pi(s)|$ , where  $\pi' = \text{greedy}(\tilde{V})$ 。究竟是否讲的是一回事，有点分不清，原因是不太清楚  $\pi' = \text{greedy}(\tilde{V})$  是怎么来的。

通过上述定理可以找到一个步长  $\alpha$  使得 policy improvement lower bound 最大。

**Corollary 4.2.** Let  $R$  be the maximal possible reward and  $\mathbb{A}$  be the policy advantage of  $\pi'$  with respect to  $\pi$  and  $\mu$ . If  $\mathbb{A} \geq 0$ , then using  $\alpha = \frac{(1-\gamma)\mathbb{A}}{4R}$  guarantees the following policy improvement:

$$\eta_\mu(\pi_{\text{new}}) - \eta_\mu(\pi) \geq \frac{\mathbb{A}^2}{8R}.$$

知乎 @张楚珩

### 3.2 Greedy policy chooser

假设我们能够获得一个比较好的找到策略  $\pi^*$  的方法，即能找到一个  $\pi^*$  比最好的能找到的情况差注意到不了多少，即

**Definition 4.3.** An  $\varepsilon$ -greedy policy chooser,  $G_\varepsilon(\pi, \mu)$ , is a function of a policy  $\pi$  and a state distribution  $\mu$  which returns a policy  $\pi'$  such that  $\mathbb{A}_{\pi, \mu}(\pi') \geq \text{OPT}(\mathbb{A}_{\pi, \mu}) - \varepsilon$ , where  $\text{OPT}(\mathbb{A}_{\pi, \mu}) \equiv \max_{\pi'} \mathbb{A}_{\pi, \mu}(\pi')$ . 知乎 @张楚珩

注意，从这里开始一直到最后面， $\varepsilon$  都应该是代表 greedy policy chooser 的误差，和 (3.1) 中的  $\varepsilon$  以及 Theorem 4.1 中的  $\varepsilon$  都不一样。Theorem 4.1 中的  $\varepsilon$  用于得到 Corollary 4.2 之后就没再用到了。

该 greedy policy chooser 隐含了 policy evaluation 和 policy improvement 两项。它获取的方式可以先得到一个 value function approximator

$$E_{s \sim d_{\pi, \mu}} \max_a |A_\pi(s, a) - f_\pi(s, a)|.$$

如果它的误差能够控制到小于  $\varepsilon/2$ ，那么选取关于它的 greedy policy 就可以组成一个  $\varepsilon$ -greedy policy chooser。显然 greedy policy chooser 也是需要一定的 sample complexity 来完成的，文章把它作为一个黑盒子，没有具体分析。

### 3.3 Sketch of CPI

CPI 的大致步骤如下：

- (1) Call  $G_\varepsilon(\pi, \mu)$  to obtain some  $\pi'$
- (2) Estimate the policy advantage  $\mathbb{A}_{\pi, \mu}(\pi')$
- (3) If the policy advantage is small (less than  $\varepsilon$ ), STOP and return  $\pi$ .
- (4) Else, update the policy and go to (1). 知乎 @张楚珩

由于对于  $\hat{\mathbb{A}}$  的估计可能会有一些误差，具体细节如下：

- (1) Call  $G_\varepsilon(\pi, \mu)$  to obtain some  $\pi'$
- (2) Use  $O(\frac{R^2}{\varepsilon^2} \log \frac{R^2}{\delta \varepsilon^2})$   $\mu$ -restarts to obtain an  $\frac{\varepsilon}{3}$ -accurate estimate  $\hat{\mathbb{A}}$  of  $\mathbb{A}_{\pi, \mu}(\pi')$ .
- (3) If  $\hat{\mathbb{A}} < \frac{2\varepsilon}{3}$ , STOP and return  $\pi$ .
- (4) If  $\hat{\mathbb{A}} \geq \frac{2\varepsilon}{3}$ , then update policy  $\pi$  according to equation 4.1 using  $\frac{(1-\gamma)(\hat{\mathbb{A}} - \frac{\varepsilon}{3})}{4R}$  and return to step 1. 知乎 @张楚珩

关于该算法有如下定理：

**Theorem 4.4.** *With probability at least  $1 - \delta$ , conservative policy iteration: i) improves  $\eta_\mu$  with every policy update, ii) ceases in at most  $72 \frac{R^2}{\epsilon^2}$  calls to  $G_\epsilon(\pi, \mu)$ , and iii) returns a policy  $\pi$  such that  $OPT(\mathbb{A}_{\pi, \mu}) < 2\epsilon$ .*

该定理回答了之前的几个问题。

首先，虽然我们关心的是  $\eta_\mu$  但是在使用 restart distribution  $\mu$  之后，可以保证  $\eta_\mu$  有 policy improvement。

其次，第 2 步中的结论只需利用 Hoeffding 不等式即可。当第 4 步中的条件满足时，可以保证  $\mathbb{A}$  的真实值一定大于  $\epsilon/3$ ，这样能够保证每次 improve 的量都不小于  $\frac{\epsilon^2}{72R}$ ，其中  $R$  为最大的 cumulative reward。另外注意到总体 performance 有上界，因此可以算出迭代次数的上界。

最后，当第 3 步中的条件满足时，可以证  $\mathbb{A}$  的真实值一定小于  $\epsilon$ ，再考虑到 policy chooser 为  $\epsilon$ -greedy，因此可以得知  $OPT(\mathbb{A}) < 2\epsilon$ 。我们会看到，这个条件可以被转化为 optimality 条件。

### 3.4 Optimality

如果从某个 restart distribution 出发，某个策略对应的  $\mathbb{A}_{\pi, \mu}$  再找不到可以使它大幅改进策略，那么该策略的性能比较接近最优策略的性能。不过前提是 restart distribution 需要和最优策略下的稳态分布比较接近。以下定理说明了这一点，注意把它和专栏上一篇里面的 gradient domination 作比较，gradient domination 说明了 gradient 小的时候接近最优。

**Corollary 4.5.** *Assume that for some policy  $\pi$ ,  $OPT(\mathbb{A}_{\pi, \mu}) < \epsilon$ . Let  $\pi^*$  be an optimal policy. Then*

$$\begin{aligned} \eta_D(\pi^*) - \eta_D(\pi) &\leq \frac{\epsilon}{(1-\gamma)} \left\| \frac{d_{\pi^*, D}}{d_{\pi, \mu}} \right\|_\infty \\ &\leq \frac{\epsilon}{(1-\gamma)^2} \left\| \frac{d_{\pi^*, D}}{\mu} \right\|_\infty. \end{aligned}$$

知乎 @张楚珩

其证明过程和 gradient domination 类似。

## 4. 讨论

原则上来说存在一个最优策略使得关于  $\eta_\mu$  和  $\eta_\pi$  能够被同时最大化，但是 CPI 只保证每回合  $\eta_\mu$  有 policy improvement。那要是把算法里面的  $\mu$  都换成  $D$  呢？首先，这样不能保证得到的策略较优。

当  $\mu$  分布比较均匀的时候，能保证不过最优策略下的稳态分布如何，Corollary 4.5 中的上界都比较小，而一个分布不太均匀的  $\mu$  不能保证这一点。其次，有时候能产生 large advantage 的状态不是从  $\mu$  出发能经常访问到的状态（考虑前面 sparse reward 的例子），因此相比于  $OPT(\mathbf{A}, \mu)$ ，不容易得到一个较大的  $OPT(\mathbf{A}, \mu)$ 。

如何选择 restart distribution 呢？可以根据先验选择最优策略容易访问到的状态。

发布于 2019-08-23

强化学习 (Reinforcement Learning)

▲ 赞同 20 ▼    1 条评论    分享    喜欢    收藏    ...

文章被以下专栏收录

 强化学习前沿  
读呀读paper

进入专栏